

# UTILIZANDO FERRAMENTAS DE OCR PARA LER DOCUMENTOS HISTÓRICOS MANUSCRITOS EM PORTUGUÊS: UM ESTUDO DE CASO

**Marcelle Alexandra Silveira Rosa** – [marcellealexandra@gmail.com](mailto:marcellealexandra@gmail.com)

**Renata Couto Vista** – [rcoutov@gmail.com](mailto:rcoutov@gmail.com)

**Giancarlo Cordeiro da Costa** – [gian.costa@gmail.com](mailto:gian.costa@gmail.com)

Universidade do Estado do Rio de Janeiro, Faculdade de Ciências Exatas e Engenharias – Rio de Janeiro, RJ, Brazil

**Resumo:** *A transcrição de manuscritos históricos continua a ser uma tarefa desafiadora, especialmente para documentos em português, devido a diversos fatores que afetam a precisão das tecnologias de Reconhecimento Óptico de Caracteres (OCR). Este estudo avaliou o desempenho de três ferramentas de OCR: Google Vision, Docsumo e Transkribus. O estudo de caso tem como objetivo não apenas testar as ferramentas disponíveis, mas destacar os desafios na obtenção de transcrições confiáveis e precisas de manuscritos históricos em língua portuguesa, sublinhando a necessidade de avanços adicionais na tecnologia de OCR.*

**Palavras-Chaves:** *OCR, transcrição de manuscrito, pesquisa histórica.*

**Abstract:** *The transcription of historical manuscripts remains a challenging task, particularly for documents in Portuguese, due to various factors affecting the accuracy of Optical Character Recognition (OCR) technologies. This study evaluated the performance of three OCR tools: Google Vision, Docsumo, and Transkribus. The case study aims not only to test the available tools but also to highlight the challenges in achieving reliable and accurate transcriptions of historical manuscripts in Portuguese, emphasizing the need for further advancements in OCR technology.*

**Keywords:** *OCR, manuscript transcription, historical research.*

## 1. INTRODUÇÃO

A tecnologia OCR (*Optical Character Recognition*) existe desde o início do século XX. O primeiro projeto documentado a utilizar OCR foi o *Optophone*, uma máquina que convertia texto em sons para auxiliar deficientes visuais. Com o passar do tempo, a tecnologia se tornou mais robusta. Nos anos 1950, houve o desenvolvimento do GISMO, uma máquina capaz de transformar texto em linguagem de máquina, representando um grande avanço na tecnologia OCR. Esse progresso permitiu a utilização de OCR para diversas finalidades em softwares comerciais na década de 1990, principalmente na digitalização de documentos aumentando a facilidade na busca de informações em documentos, por exemplo (TRIPATHI, 2024). Atualmente, uma das ferramentas de OCR mais populares é o *Tesseract*. Embora seja uma ferramenta *open-source*, o Google é o principal colaborador e financiador do projeto desde 2005.

Há também o que se denominou como ICR (Intelligent Character Recognition), um avanço do OCR nos anos 1970, que permitiu a detecção de fontes manuscritas. É aqui onde queremos focar nossa atenção. Especificamente, o ICR permite a detecção de fontes escritas à mão, diferentemente do OCR, que tem seu foco de treinamento em documentos com fontes impressas. Essa tecnologia abriu uma série de possíveis utilizações e foi amplamente utilizada, na época, por sistemas bancários para ler automaticamente cheques, por exemplo (TRIPATHI, 2023).

Tecnicamente, o ICR é um tipo de OCR que utiliza a visão computacional da mesma maneira para detectar textos escritos à mão em imagens. No entanto, seu custo acaba sendo maior que o OCR, pois necessita de mais poder de processamento, uma vez que a variação na escrita manual é maior do que em textos impressos. Além disso, o ICR exige algoritmos mais sofisticados para lidar com diferentes estilos de escrita e formatos de caracteres, tornando-o mais completo e exigente em termos de recursos computacionais.

Apesar disso, o ICR se torna um recurso valioso para pesquisas históricas e encontra espaço nas Humanidades Digitais, um campo que busca a interdisciplinaridade e se propõe a trabalhar com grandes volumes e variedades de dados para objetivos como preservação, uso e acesso. Esse campo utiliza ferramentas digitais para analisar, interpretar e preservar registros históricos, facilitando o estudo e a compreensão de períodos passado.

Torna-se cada vez mais difícil conceber pesquisas científicas sem um aparato tecnológico robusto, por isso a integração das pesquisas históricas com tecnologias avançadas, como o ICR, se torna cada vez mais relevantes. Assim, temos um vasto universo de possibilidades que também precisam ainda ser exploradas.

Embora a transcrição de manuscritos históricos utilizando OCR seja encontrada em outras partes do mundo, com esforços em fontes manuscritas medievais e otomanas desde o século XVII até o XIX (<https://www.transkribus.org/public-models>), por exemplo, não foram encontrados exemplos específicos de transcrição em língua portuguesa do Brasil. O esforço é testar ferramentas já disponíveis, sejam gratuitas ou pagas desde que com período gratuito para teste, para entender como cada uma delas se sai na leitura de documentos manuscritos em português dos séculos XVIII e XIX.

## **2. OBJETIVOS**

Este estudo de caso tem como objetivo principal avaliar a performance de três plataformas de OCR — Google Vision, Transkribus e Docsumo — na transcrição de manuscritos históricos em português do Brasil. Ao testar dez palavras legíveis, pretendemos identificar qual dessas ferramentas oferece maior precisão, fornecendo um entendimento sobre sua eficácia e utilidade para a pesquisa histórica. Os resultados obtidos permitirão determinar qual plataforma é mais adequada para lidar com a complexidade de manuscritos históricos, auxiliando pesquisadores na escolha da ferramenta mais confiável para suas necessidades.

## **3. METODOLOGIA**

Neste estudo de caso, utilizamos trechos de manuscritos da coleção Freire Alemão disponível no website da Biblioteca Nacional, sendo essa uma coleção com mais de 700 documentos que abrange de 1704 até 1948, no qual foram escolhidas dez palavras de um documento de 1851 em decorrência de sua boa legibilidade, intitulado “Apontamentos que poderão servir para a história das árvores florestais do Brasil, particularmente das do Rio de Janeiro. 2ª leitura. [Trata especificamente do pau-brasil 1851(?)]” (Fig. 1) para os testes.




Figura 1 – Trecho do documento digital mss1425049 da coleção Freire Alemão.

Os testes mediram a acurácia que avalia o desempenho, observando a precisão atingida pelo modelo, identificando se as ferramentas utilizadas são de fato úteis para a pesquisa histórica quando envolvem manuscritos históricos em português do Brasil, os resultados podem ser observados através do gráfico abaixo (fig. 2):














Figura 2 – Gráfico de Resultados obtidos

Foram testadas três ferramentas diferentes: o Google Vision, por ser uma ferramenta bastante popular e possuir o *Tesseract* como seu mecanismo de OCR subjacente; o *Transkribus*, uma plataforma comercial que possui diversos modelos específicos para manuscritos históricos que podem servir como base para treinamento

de modelos; e o *Docsumo*, uma ferramenta comercial que possui um scanner gratuito para testes mais focada em ambientes corporativos.

Tabela 1 – Resultados obtidos

| <i>Imagem</i>                                                                       | <i>Transcrição Esperada</i> | <i>Google Vision</i> | <i>Transkribus</i> | <i>Docsumo</i> |
|-------------------------------------------------------------------------------------|-----------------------------|----------------------|--------------------|----------------|
|    | Brasil                      | Brasil               | deazel             | Brasil.        |
|    | Lamarck                     | Lamarck              | Lauaite            | Lamarck        |
|    | Species                     | Species              | apecier            | Species        |
|    | ibirapitanga                | ibirapitary          | bii pstavi         | ibirapitavy    |
|   | figura                      | figure               | figuu              | figure         |
|  | Europa                      | Eunf.                |                    | Eunf.          |
|  | entanto                     | Pentant.             |                    | Tentant.       |
|  | 1783                        | 1903                 | 1208               | 1703           |
|  | 1825                        | 1825                 | 1226               | 1825           |
|  | 1658                        | 1658                 | 163s               | 1658           |

Como podemos observar através dos resultados mais detalhados da Tabela 1, o Google Vision e o *Docsumo* obtiveram o mesmo desempenho. Embora não tenha alcançado uma precisão de 100% em algumas palavras como “figura”, chegaram bem próximo de um resultado totalmente satisfatório. Com uma acurácia de 40%, os modelos ainda estão aquém do nível necessário para serem considerados úteis para pesquisas históricas. Eles obtiveram o mesmo resultado porque provavelmente o *Docsumo* utiliza-se do modelo do *Tesseract*, assim como o Google Vision. No entanto, foram observadas pequenas diferenças, como no caso do número “1783”, que o Google

Vision interpretou como “1903” e o *Docsumo* como “1703”, acertando um algarismo a mais. Numa análise mais ampla, onde um trecho maior foi testado, nenhuma das duas ferramentas conseguiria transcrever o documento de maneira com alto nível de precisão, como podemos observar na fig. 3.




Figura 3 - Teste trecho manuscrito na ferramenta Docsumo

O *Transkribus*, sendo uma plataforma especializada, era esperado que apresentasse um desempenho superior, mas os resultados não corresponderam às expectativas. Durante os testes, as opções de linguagem para português e estilo manuscrito foram selecionadas, contudo, a ferramenta não conseguiu ler palavras isoladas (Fig. 4), somente trechos maiores.




Figura 4 - Leitura de palavra isolada na plataforma Transkribus

Por isso, os resultados apresentados na tabela 1 referem-se ao trecho lido pela plataforma, identificando as palavras através da seleção de sentenças disponível (Fig. 5).

A acurácia obtida, como observamos na Tabela 1, foi de 0% e mesmo não sendo o escopo desse estudo de caso, é importante ressaltar que a plataforma permite realizar o treinamento de modelos, o que provavelmente, se realizado, resultará em uma saída mais precisa.




Figura 5 - Trecho transcrito pela plataforma Transkribus

#### 4. CONCLUSÃO

Como os resultados dos testes demonstram, a transcrição de manuscritos históricos continua a ser uma tarefa desafiadora, especialmente para documentos de língua portuguesa. Embora as ferramentas avaliadas apresentem certo potencial, ainda enfrentam desafios que impedem uma acurácia plenamente satisfatória.

A análise indica que, apesar de algumas ferramentas apresentarem alguma acurácia, ainda está longe da precisão desejada. A complexidade dos documentos históricos, que inclui desde variabilidade da escrita manuscrita, regras ortográficas e a própria conservação dos acervos brasileiros contribui para esse cenário. Esses desafios são enfrentados também em parte pela tendência dos modelos de OCR desconsiderarem palavras escritas de maneira não convencional e terem maior dificuldade com imagem que contenham ruídos visuais, o que muitas vezes é uma realidade na documentação histórica.

Assim, todos esses fatores indicam a necessidade de melhorias nas tecnologias atuais, sendo evidente que avanços adicionais são necessários para alcançar resultados mais precisos e confiáveis na transcrição de manuscritos históricos.

## 5. REFERÊNCIAS

Catálogo de Coleções de Manuscritos:

[http://catcrd.bn.br/scripts/odwp032k.dll?t=nav&pr=manuscritos\\_guia\\_pr&db=manuscriptos\\_guia&use=kw\\_livre&rn=3&disp=card&sort=off&ss=22422328&arg=freire](http://catcrd.bn.br/scripts/odwp032k.dll?t=nav&pr=manuscritos_guia_pr&db=manuscriptos_guia&use=kw_livre&rn=3&disp=card&sort=off&ss=22422328&arg=freire)

TRIPATHI, Pankaj. (2024). The Brief History of OCR Technology. Docsumo. <https://www.docsumo.com/blog/optical-character-recognition-history> acessado em 15 de julho de 24.

TRIPATHI, Pankaj. (2023). What is Intelligent Character Recognition?. Docsumo. <https://www.docsumo.com/blog/intelligent-character-recognition-icr> acessado em 15 de julho de 24.

Sergio Torres Aguilar, Vincent Jolivet. Handwritten Text Recognition for Documentary Medieval Manuscripts. 2023. hal-03892163v2f

Chammas, Edgard & Mokbel, Chafic & Likforman-Sulem, Laurence. (2018). Handwriting Recognition of Historical Documents with Few Labeled Data. 43-48. DOI: 10.1109/DAS.2018.15.

<https://www.docsumo.com/free-tools/online-ocr-scanner>

<https://www.transkribus.org/>

<https://cloud.google.com/vision/docs/drag-and-drop?hl=pt-br>