

XVI ENCONTRO NACIONAL DE ACERVOS RAROS
“OBRAS RARAS NACIONAIS E ESTRANGEIRAS: IDENTIFICAR, ADMINISTRAR, DIFUNDIR E PRESERVAR”

TRANSCRIÇÃO DE MANUSCRITOS HISTÓRICOS ATRAVÉS DE INTELIGÊNCIA ARTIFICIAL

**desafios, métodos e experiências a partir da
Coleção Freire Alemão da Fundação Biblioteca Nacional**



MARCELLE ALEXANDRA ROSA
marcellealexandra@gmail.com

SUMÁRIO

1. Apresentação

2. A coleção Freire Alemão

3. Testando ferramentas para transcrição

4. Experimentando criar uma rede neural convolucional e seus desafios

5. Resultado e conclusão

6. Referências Bibliográficas


DESAFIO

Crescente necessidade de digitalização, preservação e acesso aos acervos históricos.


Manuscritos históricos apresentam desafios técnicos, especialmente para línguas como o português.

ABORDAGEM

O trabalho explora a aplicação de inteligência artificial (IA) e visão computacional na transcrição de manuscritos históricos.





**IA, MACHINE LEARNING
E DEEP LEARNING:
É TUDO A MESMA COISA?**



O Deep Learning foi inicialmente teorizado nos anos 1980, mas só se tornou útil recentemente porque:

- Requer grandes quantidades de dados rotulados
- Requer poder computacional significativo (GPUs de alto desempenho)






Restoring and attributing ancient texts using deep neural networks

[Yannis Assael](#) , [Thea Sommerschild](#) , [Brendan Shillingford](#), [Mahyar Bordbar](#), [John Pavlopoulos](#), [Marita Chatzipanagiotou](#), [Ion Androutsopoulos](#), [Jonathan Prag](#) & [Nando de Freitas](#)

[Nature](#) **603**, 280–283 (2022) | [Cite this article](#)

129k Accesses | **145** Citations | **1009** Altmetric | [Metrics](#)
<https://www.nature.com/articles/s41586-022-04448-z>



DANISH GOTHIC HANDWRITING 19TH CENTURY - HANDWRITTEN
 Danish Gothic handwriting 19th c... Aarhus City Arc...

 Danish
 984,735 words

<https://app.transkribus.org/models/public>

Step-by-step Training Guide Using Spanish Numbers Dataset

Spanish Numbers Dataset is a small dataset of 485 images containing handwritten sentences (for training and 187 for testing).




<https://github.com/jpuigcerver/Laia/tree/master>



Contextualising ancient texts with generative neural networks


Salve! Welcome to Aeneas' interactive interface. Please follow the instructions below to begin contextualising, restoring and attributing Latin inscriptions. You will also find more information on the Aeneas project, links to the article and examples of Aeneas in action.



<https://predictingthepast.com/aeneas>

Desafios dos documentos históricos manuscritos

- Variedade de caligrafias
- Ruído e qualidade da imagem
- Tamanho e espaçamento variáveis
- Símbolos, abreviações e caracteres especiais
- Orientação e alinhamento
- Mistura de conteúdos
- Variações linguísticas
- Problemas de segmentação
- Escassez de dados rotulados



A COLEÇÃO FREIRE ALEMÃO E COMO PODEMOS UTILIZAR ESSAS FERRAMENTAS NAS CIÊNCIAS HUMANAS




Imagem de “Estudos botânicos e descrições de plantas brasileiras” (1834-1866) compostos por 17 documentos que totalizam 3850 páginas.

Sessão de Manuscritos

A Coleção Freire Alemão é composta por estudos e desenhos sobre medicina e botânica; notas de expedições e pesquisas; diários pessoais e correspondências.

Mais de 700 documentos e 655 gravuras.



nomes científicos

Casalpinia echinata

ortografia

abreviações

nomes próprios

data

pontuações

I. 28, 6, 19
Casalpinia Plum. Brasil — 1763
Casalpinia echinata Lamark = Janne P. Hilario = Martius
Guilandina echinata Sprengel 1825
Casalp. echinata? ou potius severa Guilandina spec? del
(Sprengel nuda nota del.) 1825
Apalp. echinata — not for an Guilandina species — Kunth. 1825
Kamppechia — Adans.
Casalp. echinata (Lamark) fructus in Plum echinata,
et forte non omnia congener — Jusseu — Gen. plant. 1789
ibirapitany — Pison — 1658 (figure)
Parea f. o. n. o. p. Brasil f. i. p. p. r. m. u. u.
describ. — desenhado em obra de Pison 1658
o Juss. Casalpinia fr. prop. per Plum. em 1763
Lamark na sua illustr. du Juss. (classe) o Brasil
designando-o por Casalpinia echinata

TESTANDO FERRAMENTAS DE TRANSCRIÇÃO

Transkribus

Platform & FeaturesSolutionsResourcesThe co-opPlans & pricingNew

Language: Portuguese

HandwrittenPrint

2

T.28,6,30

Amaytin = talver se devala ambaitinga embaita, ou fiqueria branca, ou tambem ambaitin, fiqueria pequena. Me inclin a pen- sar assim porq. Acciohi, na cora- grafia Paraense descreve hua Ambauba com as particulari- dades seguintes: «folhas quasi como a da Figueira ... o fruto das manas he como cacho de uvas, cujos bagos do tama- nho e cor de hum figo preto pe- queno, saõ doces e saborosas. Julgo pois q. he a planta lig. fide o A. hua Cecropia...

226620

2

Amaushia taloir se devaler aiubaitinga embaita, ousiquera traucao tambems ambaiho, fiqueira sequeua Meiuzeleiro a gen ta astimporq eRecioleua cora nratir caracude descrevehuã eeito auba com as particulare dadeo dequinteio; felhas quare coiuo a dadigueua ofreito daõ mauoaõ he coruo eocho de iiras, cujos tagas do taa nho ecor dehum diao nrito ne=


Upload another image

PDFDocCopy to clipboard



By uploading an image, you accept our terms and conditions and our privacy policy

A handwritten manuscript snippet on aged paper. At the top right, it is labeled 'T.28,6,30'. The text is written in a cursive script. It begins with '2' and 'Amaytin = talver se devala ambaitinga embaita, ou fiqueria branca, ou tambem ambaitin, fiqueria pequena. Me inclin a pen- sar assim porq. Acciohi, na cora- grafia Paraense descreve hua Ambauba com as particulari- dades seguintes: «folhas quasi como a da Figueira ... o fruto das manas he como cacho de uvas, cujos bagos do tama- nho e cor de hum figo preto pe- queno, saõ doces e saborosas. Julgo pois q. he a planta lig. fide o A. hua Cecropia...'. The text is somewhat faded and has some ink bleed-through from the reverse side.

transkribus



google vision



docsumo



Dataset Freire_Alemao


200 palavras rotuladas,
incluindo nomes, numerais
e vocabulário histórico.



Elaborado pelo autor


Processo e Ferramentas





Resultado


A rede foi treinada utilizando um conjunto de dados dividido entre treino (80%) e validação (20%), com imagens em tons de cinza e resolução 224x224 pixels.



Elaborado pelo autor

BENEFÍCIOS

- **Controle e Segurança de Dados:** Processamento local e proteção contra uso indevido.
- **Acurácia Específica:** Treinamento especializado na caligrafia histórica do Brasil.
- **Validação Científica:** Transparência e auditabilidade das transcrições.
- **Flexibilidade e Evolução:** Capacidade de adaptação, atualização e expansão para novos acervos.
- **Credibilidade Institucional:** Reforço do papel como zelador do patrimônio e polo de inovação.



Referências

Bibliográficas

AGUILAR, Sergio Torres; JOLIVET, Vincent. **Handwritten Text Recognition for Documentary Medieval Manuscripts**. 2023. Disponível em: <https://hal.archives-ouvertes.fr/hal-03892163v2>. Acesso em: 16 abr. 2025.

BIBLIOTECA NACIONAL. **Catálogo de Coleções de Manuscritos – Freire Alemão**. Disponível em: http://catcrd.bn.br/scripts/odwp032k.dll?t=nav&pr=manuscritos_guia_pr&db=manuscritos_guia&use=kw_livre&rn=3&disp=card&sort=off&ss=22422328&arg=freire. Acesso em: 16 abr. 2025.

BAG, Siddhartha; CHAUDHURI, Bidyut B. **An approach for detecting and cleaning of struck-out handwritten text**. Pattern Recognition Letters, [S. l.], v. 94, p. 1–7, 2017. DOI: 10.1016/j.patrec.2017.04.002. Disponível em: <https://doi.org/10.1016/j.patrec.2017.04.002>. Acesso em: 16 abr. 2025.

BLUCHE, Théodore; PUIGCERVER, Joan; MAIGROT, Nathaniel. **Are Multidimensional Recurrent Layers Really Necessary for Handwriting Text Recognition?** International Conference on Document Analysis and Recognition (ICDAR), 2017, Kyoto. Anais [...]. IEEE, 2017. p. 67–72. DOI: 10.1109/ICDAR.2017.20.

CHAMMAS, Edgard; MOKBEL, Chafic; LIKFORMAN-SULEM, Laurence. **Handwriting Recognition of Historical Documents with Few Labeled Data**. In: DOCUMENT ANALYSIS SYSTEMS (DAS), 2018. p. 43–48. DOI: <https://doi.org/10.1109/DAS.2018.15>. Acesso em: 16 abr. 2025.

DACOS, Marin et al. **Manifesto das Humanidades Digitais**. Tradução de Hervé Théry. 2010. Disponível em: <https://humanidadesdigitais.org/manifesto-das-humanidades-digitais/>. Acesso em: 16 abr. 2025.

DOCSUMO. **Online OCR Scanner**. Disponível em: <https://www.docsumo.com/free-tools/online-ocr-scanner>. Acesso em: 16 abr. 2025.

GOOGLE CLOUD. Documentação – **Cloud Vision API: Arrastar e soltar imagens**. Disponível em: <https://cloud.google.com/vision/docs/drag-and-drop?hl=pt-br>. Acesso em: 16 abr. 2025.

SÁNCHEZ, Joan Puigcerver; MESTRE, Santiago; VIDAL, Enrique. **HTR-Flor: A Deep Learning System for Offline Handwritten Text Recognition**. Journal of Pattern Recognition Research, [S. l.], v. 1, n. 1, p. 1–14, 2019. DOI: 10.13140/RG.2.2.30468.12160. Disponível em: <https://arxiv.org/abs/1907.08772>. Acesso em: 16 abr. 2025.

TRANSKRIBUS. **AI-powered Handwritten Text Recognition Platform**. Disponível em: <https://www.transkribus.org/>. Acesso em: 16 abr. 2025.