

**UNIVERSIDADE DO ESTADO DO RIO DE JANEIRO**  
**FACULDADE DE CIÊNCIAS EXATAS E ENGENHARIAS**  
**ANÁLISE E DESENVOLVIMENTO DE SISTEMAS**

**MARCELLE ALEXANDRA PEREIRA DA SILVEIRA ROSA**

**APLICAÇÃO DE OCR E INTELIGÊNCIA ARTIFICIAL NA LEITURA DE**  
**DOCUMENTOS MANUSCRITOS:** Um Estudo sobre a Coleção Freire Alemão da  
Biblioteca Nacional

Rio de Janeiro - RJ  
2023

MARCELLE ALEXANDRA PEREIRA DA SILVEIRA ROSA

**APLICAÇÃO DE OCR E INTELIGÊNCIA ARTIFICIAL NA LEITURA DE  
DOCUMENTOS MANUSCRITOS:** Um Estudo sobre Coleção Freire Alemão da  
Biblioteca Nacional

Projeto de Pesquisa do Curso de  
Análise e Desenvolvimento de  
Sistemas da Universidade do Estado  
do Rio de Janeiro.

Rio de Janeiro - RJ

2023

*“Nada começa com ciência; tudo começa com histórias.”*

(David A. Sinclair)

## INTRODUÇÃO

### *Computação e Humanidades, uma conexão interdisciplinar*

A evolução tecnológica tem como um dos seus objetivos facilitar a vida humana em muitos aspectos. Nesse sentido, procuramos aplicá-la nas mais diferentes áreas de conhecimento, inclusive em pesquisas científicas, potencializando novas pesquisas e possibilitando diferentes dimensões acadêmicas. Contudo, é claro que ainda temos muito a avançar quando tratamos da tecnologia no campo das Humanidades.

A pesquisa no campo da História, Ciências Sociais, Letras e Artes tem avançado muito lentamente nesse sentido, apesar de vivermos em um mundo cada vez mais *high tech*. A busca de uma interdisciplinaridade se faz necessária a partir da digitalização da vida e encontrou espaço no que hoje chama-se Humanidades Digitais, ou HD, um campo de pesquisas que reúne diferentes profissionais para tornar real trabalhos que utilizam recursos computacionais sob uma nova perspectiva.

As Humanidades Digitais se propõe a trabalhar com volume e variedade de dados. Preservação, uso e acesso. Metodologias e ferramentas computacionais e letramento digital. Para isso, baseia-se nos conceitos de *big data*, lógica computacional (algoritmos), inteligência artificial e LOD ou *link open data*. A definição do campo descrita no documento “Manifesto das Humanidades Digitais” redigido após a realização do THATCamp (*The Humanities and Technology Camp*) na cidade de Paris em 2010 diz:

“A opção da sociedade pelo digital altera e questiona as condições de produção e divulgação do conhecimento.

Para nós, as humanidades digitais referem-se ao conjunto das Ciências Humanas e Sociais, às Artes e às Letras. As humanidades digitais não negam o passado; apoiam-se, pelo contrário, no conjunto dos paradigmas, saber fazer e conhecimentos próprios dessas disciplinas, mobilizando simultaneamente os instrumentos e as perspectivas singulares do mundo digital.

As humanidades digitais designam uma transdisciplina, portadora dos métodos, dos dispositivos e das perspectivas heurísticas ligadas ao digital no domínio das Ciências Humanas e Sociais.” (MANIFESTO DAS HUMANIDADES DIGITAIS, 2010).

Ou seja, é cada vez mais difícil conceber pesquisas científicas sem um aparato tecnológico que acaba mudando nossa relação entre a experiência e a teoria. Segundo

o historiador Pierre Lévy (2010, p.7, grifo do autor), hoje temos um “*conhecimento por simulação* que os epistemologistas ainda não inventariam” . Assim, temos um vasto universo de possibilidades que também precisam ainda ser exploradas. Esse trabalho pretende suprir uma dessas necessidades.


### *A leitura de Manuscritos e a Coleção Freire Alemão*

Toda pesquisa científica precisa de fontes, essas fontes podem ser em diversos formatos como imagens, vídeos, sons, objetos, entrevistas... Mas uma das fontes mais trabalhadas e portanto comuns, são as fontes textuais. Elas [as fontes] serão o caminho concreto de investigação para uma análise crítica e respostas para a pergunta norteadora. O Problema e a Fonte estão intimamente ligados. Se por um lado, o Problema pode sinalizar as Fontes escolhidas pelo historiador, por outro, as Fontes também podem trazer novos Problemas. Neste trabalho, foi justamente a documentação que trouxe a queixa e o motivo da pesquisa.

É comum pesquisadores de História Antiga até a História Moderna, principalmente os historiadores Modernos, dedicarem horas de seu tempo de pesquisa para transcrever documentos manuscritos. Nem sempre é fácil conseguir transcrições das fontes já prontas por alguns motivos, dentre eles pode ser porque são de difícil acesso, ou simplesmente porque ainda não existem.

Nesse sentido, a escolha da Coleção Freire Alemão se deve ao vasto conteúdo produzido pelo médico Francisco Freire Alemão que contém 796 documentos, além de 655 gravuras. Nascido no Rio de Janeiro em 1797, o médico particular de D. Pedro II, formado pela Escola Anatômica, Cirúrgica e Médica do Rio de Janeiro e doutor em medicina pela Universidade de Paris foi também professor de botânica e sócio do Instituto Histórico e Geográfico Brasileiro (IHGB).

O catálogo traz, portanto, um conteúdo muito rico não somente relativo à botânica e medicina, mas também notas de expedições, diários e notas sobre pesquisas e desenhos, além de correspondência titular e terceiros. Temos acesso também a documentos relativos à escravidão e outros documentos particulares referentes à expedição ao Ceará.



Trecho do manuscrito “Apontamentos que poderão servir para a história das árvores florestais do Brasil e particularmente do Rio de Janeiro” de 1851.

Todo esse conteúdo está disponível na Biblioteca Nacional, grande parte em formato digitalizado. Entretanto, a escassez de pesquisas sobre esse acervo substancial ressalta a oportunidade e a importância desta investigação. Tendo em vista um pesquisador que tenha intenção de trabalhar debruçado sobre esta coleção, podemos imaginar o esforço e tempo dedicados apenas à transcrição necessária para então começar a fazer toda análise histórica. Isso nos traz então, a possibilidade e o desafio de criar algo que facilite a leitura dos manuscritos com uma maior precisão em menos tempo.

#### *Através do OCR e da Inteligência Artificial*

A utilização de OCR, *Optical Character Recognition* ou Reconhecimento Óptico de Caracteres, não é novidade quando tratamos sobre leitura de documentos. Seu foco é trabalhar a detecção de caracteres em uma imagem e escrevê-la em formato de texto, possibilitando a edição e busca facilitada. Apesar dessa técnica ser amplamente utilizada para processar documentos impressos, enfrenta maior dificuldade em relação a documentos manuscritos onde encontra um desafio significativo em relação à complexidade das escritas e variações gráficas individuais.

Cada vez mais comum no nosso cotidiano, a inteligência artificial tem como propósito desenvolver sistemas que consigam realizar tarefas que normalmente exigiriam inteligência humana. Seu impacto social, político e econômico são tão reais em nosso mundo que a União Europeia pontua que a IA é “... considerada primordial para a transformação digital da sociedade e tornou-se uma prioridade da UE.”<sup>1</sup> Estados Unidos e China lideram o número de pesquisas publicadas na área com milhares de trabalhos publicados anualmente.<sup>2</sup> Segundo uma pesquisa realizada pela Vox Media com mais de 2 mil norte-americanos, em 2023, 1 em cada 3 pessoas já usou uma ferramenta de Inteligência Artificial.<sup>3</sup>

A Academia Brasileira de Ciências (ABC) publicou em novembro de 2023, “Recomendações para o avanço da inteligência artificial no Brasil” e pontua que:

“O Brasil não pode correr o risco de ser apenas um usuário de soluções IA concebidas no exterior. A dependência de outros países e de grandes empresas nesta área pode prejudicar a segurança e a soberania nacional, além da competitividade das empresas nacionais no país e no exterior.

Os países que pretendem construir novas tecnologias com base na IA devem ter capacidade de entender os princípios do desenvolvimento dessas soluções. De outra forma, a falta de conhecimento perpetuará uma dependência cada vez maior das grandes corporações e dos países dominantes da tecnologia.” (ALMEIDA, Virgílio Augusto Fernandes, 2023, p. 4).

Nesse sentido, a pesquisa traz uma contribuição para o campo de estudos de Inteligência Artificial através da leitura de manuscritos produzidos entre os séculos XVIII e XIX e que pode ser aplicada não somente para superar limitações da OCR tradicional, como também pode utilizar algoritmos avançados de processamento de linguagem natural (PNL) e aprendizado de máquina, ou *machine learning*, para compreender e transcrever os textos manuscritos. Podendo ser treinada para reconhecer estilos de escrita específicos da época, considerando variações regionais e individuais. Utilização de modelos para lidar com a caligrafia e corrigir automaticamente erros comuns de transcrição gerados pelo OCR, melhorando a precisão e preservando a integridade do conteúdo original.

---

<sup>1</sup> [https://www.europarl.europa.eu/news/pt/headlines/society/20200827STO85804/o-que-e-a-inteligencia-artificial-e-como-funciona#:~:text=A%20intelig%C3%Aancia%20artificial%20\(IA\)%20%C3%A9,o%20planeamento%20e%20a%20criatividade](https://www.europarl.europa.eu/news/pt/headlines/society/20200827STO85804/o-que-e-a-inteligencia-artificial-e-como-funciona#:~:text=A%20intelig%C3%Aancia%20artificial%20(IA)%20%C3%A9,o%20planeamento%20e%20a%20criatividade). Acessado em 06 de dezembro de 2023.

<sup>2</sup> <https://www.insper.edu.br/noticias/sem-guerra-fria-china-e-eua-sao-os-mais-prolificos-parceiros-em-pesquisas-sobre-ia/>. Acessado em 06 de dezembro de 2023.

<sup>3</sup> <https://gizmodo.uol.com.br/1-a-cada-3-adultos-nos-eua-ja-experimentou-ferramentas-de-ia-diz-estudo/>. Acessado em 05 de dezembro de 2023.

Além de proporcionar recursos adicionais, o estudo da aplicação de inteligência artificial (IA) e OCR na leitura de documentos manuscritos, como evidenciado na Coleção Freire Alemão da Biblioteca Nacional, não apenas enriquece as ferramentas disponíveis, mas também representa um avanço significativo para a compreensão da História da Ciência no Brasil.

Ao incorporar essas tecnologias inovadoras, a pesquisa busca não apenas preservar o valioso patrimônio documental, mas também fomentar o progresso no campo tanto da História da Ciência como também na área da Computação, promovendo uma abordagem moderna e interdisciplinar, como propõe as Humanidades Digitais.

## **REFERENCIAL TEÓRICO**

O embasamento teórico desta pesquisa é sustentado por pilares distintos, sendo o primeiro deles a visão computacional direcionada ao OCR, um componente essencial para o avanço do projeto. O OCR reconhece caracteres em arquivos digitalizados convertendo tipos diferentes de documentos em arquivos digitais editáveis, ou seja, reconhece textos impressos ou manuscritos, convertendo o texto de maneira legível para o computador.

A utilização da Inteligência Artificial visa, inicialmente, otimizar o processo por meio do aprendizado de máquina. Essa abordagem oferece algumas vantagens para o treinamento do OCR, como o aprimoramento da sua habilidade de reconhecer caracteres em novas imagens, graças ao refinamento contínuo proporcionado pelo conjunto de dados utilizado no treinamento.

Há exemplos da utilização dessas tecnologias para a leitura de Escritos Antigos, como o projeto ITHACA que se identifica como:

“a primeira Rede Neural Profunda para restauração textual, atribuição geográfica e cronológica de inscrições gregas antigas. Ithaca foi projetado para auxiliar e expandir o fluxo de trabalho do historiador: sua arquitetura se concentra na colaboração, no suporte à decisão e na interpretabilidade.” (ITHACA, DeepMind, disponível em: <https://ithaca.deepmind.com/>, tradução livre).

No âmbito das Humanidades Digitais, este projeto incorpora um referencial teórico que preconiza o acesso aberto aos dados e metadados, adotando uma abordagem transparente e colaborativa. Para tal, os códigos serão versionados em diretórios e disponibilizados na plataforma GitHub, promovendo a ampla divulgação e participação da comunidade acadêmica.



Esta iniciativa, ancorada em um esforço multidisciplinar, visa criar uma base sólida para a pesquisa, estando acessível a pesquisadores de diferentes áreas do conhecimento.

Adicionalmente, o projeto assume o compromisso de apoiar a valorização e preservação do patrimônio documental nacional. Contribuindo para o desenvolvimento de novas pesquisas em diversos campos, enquanto oferece suporte aos esforços de digitalização de coleções de bibliotecas e arquivos públicos.

Destaca-se, de maneira especial, a relevância da Coleção Freire Alemão, reconhecendo seu valor histórico e ressaltando-a como uma fonte crucial para investigações interdisciplinares. Dessa forma, almeja-se não apenas avançar nas fronteiras do conhecimento, mas também fortalecer a base para futuras explorações e preservação do rico patrimônio cultural.

## **METODOLOGIA**

A metodologia do presente projeto de pesquisa perpassa o desafio da leitura de Manuscritos e nos traz questões específicas no que diz respeito à variação de caligrafia e também à variação gramatical das palavras. Há uma diferença entre tirar uma foto, expor essa foto (nesse caso a digitalização dos documentos) e ter uma aplicação capaz de transformar o que vemos em algo compreensível. Os “[...] modelos como o ITHACA podem desbloquear o potencial cooperativo entre a IA e os historiadores, impactando de forma transformacional a forma como estudamos e escrevemos sobre um dos períodos mais significativos da história da humanidade.” (ITHACA, DeepMind, disponível em: <https://ithaca.deepmind.com/>, tradução livre).

A primeira etapa da metodologia envolve a implementação e treinamento da tecnologia OCR, a partir da aquisição de imagens digitalizadas disponíveis no acervo online da Biblioteca Nacional. A seleção dos manuscritos considera critérios como o estado de conservação, diversidade de estilos de escrita e complexidade, seguida pelo pré-processamento das imagens. Este estágio visa aprimorar a qualidade das imagens, tornando o texto mais legível. Ajustes de contraste e angulação podem ser realizados nesse processo.

Em seguida, dedicaremos esforços à familiarização com a linguagem Python e bibliotecas abertas para integrar com o OCR, visando a segmentação eficiente de caracteres e linhas. Esse processo permite a divisão das imagens em unidades menores para análise individual de caracteres e linhas de texto.

O treinamento para análise de formas e padrões dos caracteres identificados na imagem será uma fase crucial do projeto. Essa etapa demandará tempo significativo, pois requer processamento intensivo para garantir resultados precisos. Será adotada a metodologia ágil para organizar e conduzir todas as etapas do projeto dentro de prazos de entrega definidos.

Nas fases finais, após o reconhecimento dos caracteres, serão realizadas correções e ajustes para aprimorar a precisão do texto resultante. Isso incluirá análises de contexto e a correção dos erros mais comuns. O objetivo central do projeto é obter uma saída textual que represente digitalmente o conteúdo do documento original. Os usuários deverão ter a capacidade de editar, armazenar e processar o texto conforme necessário, proporcionando maior acessibilidade e utilidade ao material digitalizado.

## **CONCLUSÃO**

Ao finalizar este projeto com aplicação de OCR e Inteligência Artificial para a leitura de documentos manuscritos, poderemos ter conquistas significativas no que diz respeito à maior acessibilidade ao acervo que hoje consta na Coleção Freire Alemão no site da Biblioteca Nacional.

A implementação cuidadosa do OCR, aliada a um treinamento intensivo em reconhecimento de caracteres e ao uso de aprendizado de máquina, não apenas facilitará a transição do manuscrito para o formato digital, mas também cumprirá o propósito fundamental de promover uma atuação multidisciplinar entre patrimônio cultural e tecnologia. Essa abordagem não apenas contribuirá para a expansão do campo das Humanidades Digitais, uma área em constante crescimento global, mas também representará uma significativa contribuição para pesquisas no campo de visão computacional e inteligência artificial no Brasil. Este projeto tem o potencial de ser a primeira aplicação de código aberto desse tipo no país, abrindo caminho para inovações e colaborações futuras que transcendem as fronteiras da pesquisa acadêmica.

O alcance dessa realização não se limita apenas ao âmbito acadêmico; estende-se ao público em geral, proporcionando uma plataforma acessível e interativa para a exploração do patrimônio cultural. A digitalização e interpretação avançada desses documentos manuscritos preservam nossa história e também enriquecem a compreensão coletiva de eventos passados, tradições culturais e desenvolvimentos significativos ao longo do tempo.

Vislumbramos, portanto, não apenas a transformação de manuscritos em formatos digitais, mas também corroborar com a democratização do acesso à informação e conhecimento e a transformação da maneira como nos conectamos com nossa herança cultural.

## REFERÊNCIA BIBLIOGRÁFICA

ALMEIDA, Virgílio Augusto Fernandes; et al. Recomendações para o avanço da inteligência artificial no Brasil: GT-IA da Academia Brasileira de Ciências. Rio de Janeiro, RJ: Academia Brasileira de Ciências, 2023.

ANDERSON, S., Blanke, T., Dunn, S., ‘Methodological Commons – Arts and Humanities e-Science Fundamentals’, Phil. Trans. R. Soc. A 28, vol. 368 no. 1925, 2010. <http://rsta.royalsocietypublishing.org/content/368/1925/3779.full.pdf+html>

BARROS, José. (2010). *Fontes históricas: Olhares sobre um caminho percorrido e perspectivas sobre os novos tempos*. Revista Albuquerque. 2. 71-115. 10.46401/ajh.2010.v2.3938.

BUSA, Roberto. “Foreword: Perspectives on the Digital Humanities”. In Susan Schreibman, Ray Siemens, John Unsworth (eds.). *A Companion to Digital Humanities*. Oxford: Blackwell, 2004. <http://www.digitalhumanities.org/companion/>

LÉVY, Pierre. *As Tecnologias da Inteligência. O futuro do pensamento na era da informática*. São Paulo: Editora 34, 2010.

[Pesquisadores usam IA para interpretar textos antigos jamais compreendidos - Canaltech](#) 06 de dezembro de 2023.

<https://ithaca.deepmind.com/> acessado em 06 de dezembro de 2023.

MANIFESTO, 2010 [https://issuu.com/openedition/docs/dh40x60\\_por](https://issuu.com/openedition/docs/dh40x60_por) acessado em 06 de dezembro de 2023.

R. Mittal and A. Garg, "Text extraction using OCR: A Systematic Review," 2020 Second International Conference on Inventive Research in Computing Applications (ICIRCA), Coimbatore, India, 2020, pp. 357-362, doi: 10.1109/ICIRCA48905.2020.9183326.

<https://readcoop.eu/insights/ocr-vs-htr/> Acessado em 10 de dezembro de 2023.