



Utilizando Ferramentas de OCR para ler documentos históricos manuscritos em português: um estudo de caso

Marcelle Alexandra Silveira Rosa¹, Giancarlo Cordeiro da Costa² e Renata Couto Vista³

^{1,2,3} Universidade do Estado do Rio de Janeiro, FCEE, Rio de Janeiro/RJ, Brazil

Abstract

A transcrição de manuscritos históricos continua a ser uma tarefa desafiadora, especialmente para documentos em português, devido a diversos fatores que afetam a precisão das tecnologias de Reconhecimento Óptico de Caracteres (OCR). O estudo de caso tem como objetivo não apenas testar as ferramentas disponíveis, mas destacar os desafios na obtenção de transcrições confiáveis e acuradas de manuscritos históricos em língua portuguesa, sublinhando a necessidade de avanços adicionais na tecnologia. O OCR surgiu no início do século XX, mas foi na década de 1990 que se popularizou através da digitalização de documentos. Há também o que se denominou ICR (Intelligent Character Recognition), um avanço do OCR que permitiu a detecção de fontes manuscritas, enquanto o OCR é voltado para documentos com fontes impressas (TRIPATHI,2023). Essas tecnologias têm se mostrado úteis para áreas como as Humanidades Digitais, que visam a preservação, uso e acesso a registros históricos, sendo relevantes para pesquisas históricas, onde a transcrição de manuscritos é fundamental. Apesar do uso crescente do ICR em outros países para transcrição de documentos históricos, como manuscritos medievais e otomanos, ainda há uma lacuna no uso dessa tecnologia em documentos históricos em português do Brasil. O estudo em questão tem como objetivo avaliar três ferramentas de OCR — Google Vision, Transkribus e Docsumo — quanto à sua precisão na transcrição de manuscritos históricos em português do Brasil. Utilizando dez palavras de um documento de 1851 da coleção Freire Alemão, disponível na Biblioteca Nacional, a pesquisa busca identificar qual ferramenta tem melhor desempenho.




Fig. 1: Trecho do documento digital mss1425049 da coleção Freire Alemão

O Google Vision e o Docsumo, ambos utilizando o Tesseract, mostraram resultados similares, com algumas variações em certos trechos, como na interpretação de números. No entanto, nenhuma das ferramentas conseguiu atingir 100% de precisão, demonstrando limitações na transcrição de textos manuscritos complexos. O desempenho foi de 40% de acurácia, o que indica que ainda não são ideais para aplicações históricas que exigem alta precisão. Já o Transkribus, apesar de ser uma plataforma especializada em manuscritos históricos, teve desempenho inferior às expectativas. Mostrou dificuldades em reconhecer palavras em português, obtendo resultado de 0% de acurácia. Isso sugere que, sem um treinamento específico de modelos, a ferramenta não é eficaz para a leitura precisa de manuscritos em português do Brasil. A análise conclui que a transcrição de documentos históricos em português ainda é um desafio para as ferramentas de OCR testadas. As principais dificuldades estão relacionadas à variação da escrita manual, às mudanças nas regras ortográficas ao longo do tempo e à qualidade das imagens dos documentos, que muitas vezes apresentam ruídos visuais. Embora as ferramentas testadas ofereçam um certo nível de precisão, elas ainda estão longe de serem adequadas para a pesquisa histórica que demanda resultados mais confiáveis. Portanto, melhorias são necessárias para atender às demandas dos pesquisadores que trabalham com manuscritos históricos. Apesar dos avanços existentes, há um longo caminho a ser percorrido para garantir que a transcrição de documentos históricos em português atinja um nível satisfatório de acurácia, permitindo uma melhor preservação e acesso a esses registros.

Keywords: OCR, transcrição de manuscrito, pesquisa histórica.

TRIPATHI, Pankaj. (2024). The Brief History of OCR Technology. Docsumo. <https://www.docsumo.com/blog/optical-character-recognition-history> acessado em 15 de julho de 24.

TRIPATHI, Pankaj. (2023). What is Intelligent Character Recognition?. Docsumo. <https://www.docsumo.com/blog/intelligent-character-recognition-icr> acessado em 15 de julho de 24.

Sergio Torres Aguilar, Vincent Jolivet. Handwritten Text Recognition for Documentary Medieval Manuscripts. 2023. hal-03892163v2f

Chammas, Edgard Mokbel, Chafic Likforman-Sulem, Laurence. (2018). Handwriting Recognition of Historical Documents with Few Labeled Data. 43-48. DOI: 10.1109/DAS.2018.15.

<https://www.docsumo.com/free-tools/online-ocr-scanner>

<https://www.transkribus.org/>

<https://cloud.google.com/vision/docs/drag-and-drop?hl=pt-br>

Catálogo de Coleções de manuscritos: http://catcrd.bn.br/scripts/odwp032k.dll?t=navpr=manuscritos_guia_rdb=manuscritos_guiause=kwivvern=3disp=cardsort=offss=22422328arg=freire.